Informe de Proyecto: NutriAgent - Asistente Nutricional Inteligente

Autor: Luciano Giammarini

1. El Problema a Resolver

Llevar un control diario de lo que comemos es un hábito muy difícil de mantener. Si lo hacemos anotando a mano o buscando en aplicaciones tradicionales, perdemos mucho tiempo calculando los pesos y las calorías de cada ingrediente, lo que hace que la mayoría de las personas se canse y abandone a las pocas semanas. Además, si buscamos consejos de alimentación en internet, solemos encontrar información general o dietas de moda que no siempre siguen las recomendaciones oficiales de salud de nuestro país.

Elegí desarrollar **NutriAgent** para resolver este problema usando Inteligencia Artificial. La idea es hacer que llevar un registro sea automático y fácil: solo tomo una foto de mi plato y la aplicación hace el resto. Además, me ofrece consejos nutricionales, pero no inventa las respuestas, sino que se basa únicamente en las Guías Alimentarias para la Población Argentina (GAPA).

---

2. Casos de Uso del Agente

Tengo dos casos de uso principales en este proyecto: 1. **Registro Visual de Comidas (Con IA de Visión):** Saco una foto de mi comida. La Inteligencia Artificial analiza la foto, identifica qué ingredientes hay, calcula sus porciones aproximadas y consulta la base de datos oficial (USDA) para entregarme las calorías y los nutrientes (proteínas, carbohidratos y grasas). 2. **Asistente Nutricional de Texto (Con RAG):** Es un chat en el que le puedo hacer preguntas (por ejemplo, *¿qué ceno hoy considerando lo que ya comí?*). El sistema lee mis documentos de las Guías Alimentarias (GAPA) y me responde de forma segura y confiable basándose en esa información.

---

3. Comparativa y Selección de Modelos

Para asegurar que la aplicación sea confiable y eficiente, además de económica de mantener, comparé varios modelos de IA usando los rankings más recientes. En este análisis, tuve en cuenta tres factores: qué tan bien siguen las instrucciones (Eficacia en IFEval), la rapidez con la que responden (Latencia o TTFT) y que el costo sea accesible para que el proyecto sea viable (precio por millón de tokens).

A. Para la Tarea de Visión (Analizar la foto de la comida)

Para esta tarea, consulté específicamente el ranking **"Entity Recognition" del Vision Leaderboard en Arena.ai**. Elegí este leaderboard en particular porque el caso de uso del *Photo-Tracking* requiere exactamente esta capacidad: "reconocer, identificar y explicar objetos específicos desde una imagen" (separar visualmente los ingredientes de un plato mezclado) asociándolos con conocimiento del mundo real.

> Arena.ai Entity Recognition

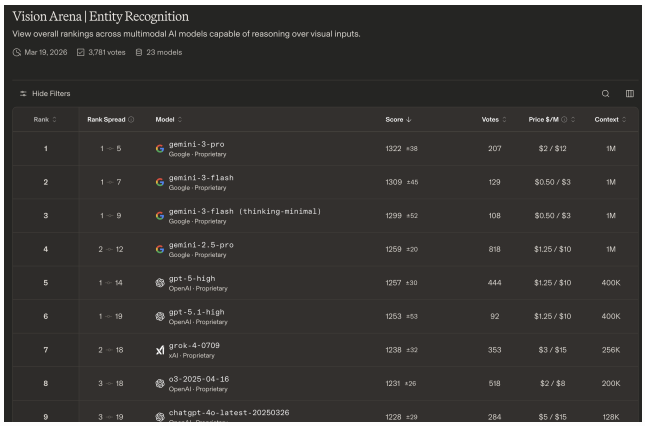

Vision Arena | Entity Recognition

View overall rankings across multimodal AI models capable of reasoning over visual inputs.

Mar 19, 2026 · 3,781 votes · 23 models

Hide Filters

Rank	Rank Spread	Model	Score	Votes	Price $/M	Context
1	1 → 5	gemini-3-pro Google · Proprietary	1322 ±38	207	$2 / $12	1M
2	1 → 7	gemini-3-flash Google · Proprietary	1309 ±45	129	$0.50 / $3	1M
3	1 → 9	gemini-3-flash (thinking-minimal) Google · Proprietary	1299 ±52	108	$0.50 / $3	1M
4	2 → 12	gemini-2.5-pro Google · Proprietary	1259 ±20	818	$1.25 / $10	1M
5	1 → 14	gpt-5-high OpenAI · Proprietary	1257 ±30	444	$1.25 / $10	400K
6	1 → 19	gpt-5.1-high OpenAI · Proprietary	1253 ±53	92	$1.25 / $10	400K
7	2 → 18	grok-4-0709 xAI · Proprietary	1238 ±32	353	$3 / $15	256K
8	3 → 18	o3-2025-04-16 OpenAI · Proprietary	1231 ±26	518	$2 / $8	200K
9	3 → 19	chatgpt-4o-latest-20250326	1228 ±29	284	$5 / $15	128K

Leaderboard Entity Recognition

Artificial Analysis Latency

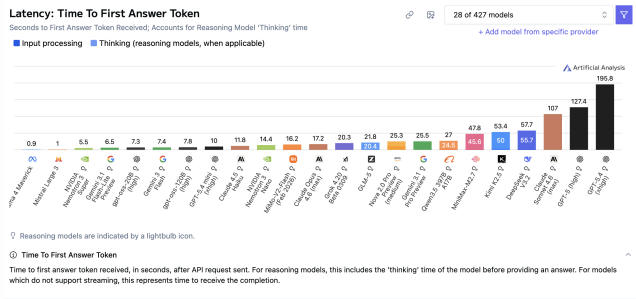

Latencia Visión

Comparé 3 modelos relevantes basándome en los resultados extraídos de dicho ranking, incluyendo sus costos vigentes y los reportes de latencia estructural provistos por **Artificial Analysis** (métrica: *Time To First Answer Token*, o TTFT):

- **Gemini 3 Pro (Google):**
  - **Eficacia:** Es el líder absoluto (Top #1 global en Entity Recognition con un Score ELO de 1322).
  - **Latencia (TTFT):** Media (~25.5 segundos de espera).
  - **Costo:** $2.00 por millón de tokens de entrada / $12.00 por millón de salida.
  - **Veredicto:** Excelente precisión, pero su demorado análisis y su costo elevado desaconsejan integrarlo a nivel masivo y en tiempo real.
- **Gemini 3 Flash (Google):**
  - **Eficacia:** Altísima (Top #2 global con un Score ELO de 1309), superando cómodamente a varios modelos “gigantes” en esta tarea.
  - **Latencia (TTFT):** Extremadamente veloz (apenas 7.4 segundos en emitir la respuesta).
  - **Costo:** $0.50 entrada / $3.00 salida por millón de tokens.
  - **Veredicto:** Representa la mejor relación entre calidad, precio y velocidad absoluta de todo el mercado para tareas de visión móvil.
- **GPT-5 High (OpenAI):**
  - **Eficacia:** Muy buena (Top #5 con un Score ELO de 1257), aunque sorprendentemente queda relegado por debajo de las versiones ligeras de Google en la disciplina de “Entity Recognition”.
  - **Latencia (TTFT):** Excesiva (127.4 segundos totales). Al ser un modelo que emplea “tiempos profundos de pensamiento” en negro antes de responder, se vuelve totalmente inoperable para un usuario interactivo móvil.
  - **Costo:** $1.25 entrada / $10.00 salida por millón de tokens.
  - **Veredicto:** Totalmente inviable (caro y lento) para la inmediatez que exige esta aplicación particular.

Mi decisión: Elegí **Gemini 3 Flash** para la tarea de captura de fotos. Ubicándose en el puesto #2 global en “Entity Recognition”, garantiza que identificará de manera impecable cada alimento dentro del plato. Lo más destacable de esta elección radica en la experiencia del usuario (*UX*): su asombrosa latencia de apenas **7.4 segundos** evita la frustrante larga espera de más de 2 minutos (127s) que tendríamos con *GPT-5 High*. Esto sumado a que cuesta una cuarta parte que la versión de su mismo nivel (“Pro”), me permite mantener la solidez técnica y viabilidad financiera del proyecto por igual.

B. Para el Chat y las Preguntas Médicas (RAG)

Para este caso de uso se necesitaba un modelo que sea muy bueno conversando, que responda rápido y que obedezca las reglas sin desviarse. Dado que mis documentos médicos RAG (las GAPA - Guías Alimentarias para la Población Argentina) están en español, descarté los rankings generales y apliqué el filtro **"Language: Spanish"** en el leaderboard de **Instruction Following (IFEval)** de Arena.ai.

Esta métrica (*IFEval Español*) es el corazón que da vida a un sistema RAG: evalúa la rigurosidad y el porcentaje en el que una IA acata instrucciones como *"Responde solo usando la información de este vector"*.

> Arena.ai Chat Spanish
>
> | Rank | Rank Spread | Model | Score | Votes | Price $/M | Context |
> |---|---|---|---|---|---|---|
> | 1 | 1 → 19 | claude-opus-4-6-thinking
Anthropic · Proprietary | 1507 ±27 | 519 | $5 / $25 | 1M |
> | 2 | 1 → 19 | claude-opus-4-6
Anthropic · Proprietary | 1505 ±27 | 533 | $5 / $25 | 1M |
> | 3 | 1 → 43 | gpt-5.4-high
OpenAI · Proprietary | 1485 ±41 | 220 | $2.50 / $15 | 1.1M |
> | 4 | 1 → 34 | gemini-3.1-pro-preview
Google · Proprietary | 1483 ±26 | 547 | $2 / $12 | 1M |
> | 5 | 1 → 32 | grok-4.1-thinking
xAI · Proprietary | 1479 ±21 | 993 | $0.20 / $0.50 | N/A |
> | 6 | 1 → 43 | claude-sonnet-4-6
Anthropic · Proprietary | 1477 ±33 | 341 | $3 / $15 | 1M |
> | 7 | 1 → 45 | gpt-5.2-chat-latest-20260210
OpenAI · Proprietary | 1476 ±34 | 315 | $1.75 / $14 | 128K |
> | 8 | 1 → 39 | kimi-k2.5-thinking
Moonshot · Modified MIT | 1476 ±27 | 500 | $0.60 / $3 | N/A |
> | 9 | 1 → 44 | dola-seed-2.0-preview
Bytedance · Proprietary | 1475 ±32 Preliminary | 367 | N/A | N/A |
> | 10 | 1 → 38 | gemini-3-pro
Google · Proprietary | 1473 ±20 | 1,054 | $2 / $12 | 1M |
> | 11 | 1 → 59 | ernie-5.0-preview-1203
Baidu · Proprietary | 1473 ±39 | 219 | N/A | N/A |
>
> Leaderboard Chat Spanish
>
> Arena.ai Instruction Following
>
> | Rank | Rank Spread | Model | Score | Votes | Price $/M | Context |
> |---|---|---|---|---|---|---|
> | 1 | 1 → 4 | claude-opus-4-6-thinking
Anthropic · Proprietary | 1508 ±11 | 2,976 | $5 / $25 | 1M |
> | 2 | 1 → 6 | claude-opus-4-6
Anthropic · Proprietary | 1502 ±10 | 3,479 | $5 / $25 | 1M |
> | 3 | 1 → 10 | gemini-3.1-pro-preview
Google · Proprietary | 1488 ±10 | 4,001 | $2 / $12 | 1M |
> | 4 | 2 → 10 | claude-opus-4-5-20251101-thinking-32k
Anthropic · Proprietary | 1486 ±7 | 9,391 | $5 / $25 | 200K |
> | 5 | 1 → 14 | gpt-5.4-high
OpenAI · Proprietary | 1485 ±16 | 1,384 | $2.50 / $15 | 1.1M |
> | 6 | 2 → 12 | claude-sonnet-4-6
Anthropic · Proprietary | 1484 ±12 | 2,673 | $3 / $15 | 1M |
> | 7 | 3 → 12 | claude-opus-4-5-20251101
Anthropic · Proprietary | 1478 ±7 | 10,997 | $5 / $25 | 200K |
> | 8 | 3 → 14 | gemini-3-pro
Google · Proprietary | 1474 ±7 | 11,287 | $2 / $12 | 1M |
> | 9 | 3 → 22 | grok-4.20-beta1
xAI · Proprietary | 1467 ±14 Preliminary | 1,747 | N/A | N/A |
> | 10 | 5 → 22 | gpt-5.2-chat-latest-20260210
OpenAI · Proprietary | 1466 ±11 | 2,825 | $1.75 / $14 | 128K |
> | 11 | 3 → 23 | gpt-5.4
OpenAI · Proprietary | 1466 ±16 | 1,423 | $2.50 / $15 | 1.1M |
> | | | claude-sonnet-4-5-20250929-thinking-32k | | | | |
>
> Leaderboard IFEval
>
> Artificial Analysis Latency
>
> 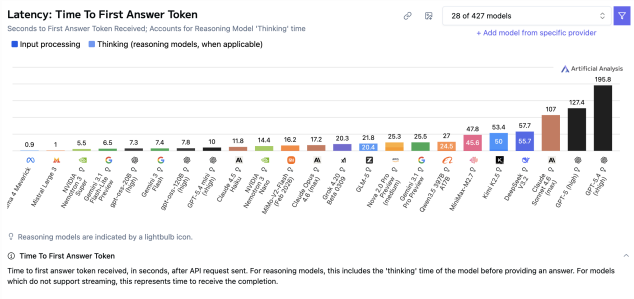
>
>
> Latencia Chat

Analicé tres modelos destacados evaluando su viabilidad combinando estas dos competencias del lenguaje:

- **Claude Opus 4.6 Thinking (Anthropic):**
  - **Eficacia (Español & IFEval):** Liderazgo absoluto. Domina cómodamente la conversación en español y es el amo indiscutido del Top #1 global acatando instrucciones (Elo 1508).
  - **Latencia (TTFT):** Lenta (17.2 segundos absolutos). Si bien es el modelo "Pensativo" más veloz, impone una pauta de espera interactiva notable.
  - **Costo:** Muy costoso para uso conversacional masivo ($5.00 entrada / $25.00 salida por millón de tokens).
  - **Veredicto:** El modelo RAG más inteligente y riguroso del mundo. Lastimosamente, este lujo escala el presupuesto a niveles financieramente hostiles para un proyecto masivo.
- **Gemini 3.1 Pro Preview (Google):**
  - **Eficacia (Español & IFEval):** Extraordinario. Brilla en la fluidez del "Chat Spanish" y mantiene un valiosísimo Top #3 global (Elo 1488) en obediencia a instrucciones. Una balanza perfecta para entender indicaciones complejas sobre las GAPA.
  - **Latencia (TTFT):** Lenta (~25.5 segundos en emitir inicio de respuesta). Ligeramente más pausado de pensar que Opus 4.6.
  - **Costo:** Equilibrado y altamente competitivo ($2.00 entrada / $12.00 salida por millón de tokens).
  - **Veredicto:** Sólido, fuerte y confiable. Soporta el peso de ambos rankings y el ahorro masivo de presupuesto lo convierte en el modelo idóneo para escalar.
- **GPT-5.4 Nano (OpenAI):**
  - **Eficacia (Español & IFEval):** Fuerte debilidad mixta. Aunque mantiene un nivel natural de charla hispana por herencia de la familia, el modelo no logra ni siquiera clasificar en el Leaderboard de *Instruction Following*. Esto es terrible para el rigor médico.
  - **Latencia (TTFT):** Impactante (**0.5 segundos**). Es el monarca indiscutido de la inmediatez en *Artificial Analysis*.
  - **Costo:** Extremadamente económico (apoyándose en fracciones centesimales estándar de modelos Ultra-Lite).
  - **Veredicto:** Descartado categóricamente. Inyectar datos médicos RAG en español a un modelo que "no sabe seguir instrucciones del prompt", por más veloz que sea (0.5s), nos garantiza severos y eventuales riesgos clínicos.

Mi decisión: Elegí **Gemini 3.1 Pro Preview**. Aunque *Claude Opus 4.6 Thinking* es el rey general (y sorpresivamente 8 segundos más veloz), su tarifa *Premium* de $5.00/$25.00 vuelve prohibitivo el proyecto masivo. *Gemini 3.1 Pro Preview* es la balanza maestra: domina el chat en español con fluidez impecable (Top ranking *Spanish*) y asegura una obediencia clínica fenomenal respaldada por su Top #3 en *Instruction Following*, costando menos de la mitad que Claude. Esto vuelve al agente viable y altamente seguro, un trato fenomenal a cambio de perder algo de inmediatez.

> *Nota sobre Búsqueda Interna:* Para buscar palabras dentro de mis documentos de salud, utilicé un modelo local y de uso libre (`paraphrase-multilingual-MiniLM-L12-v2`). Esto hace que las búsquedas internas para el Chatbot sean totalmente gratuitas e instantáneas.

Estado Actual de la Implementación

> Los modelos **Gemini 3.1 Pro Preview** (chat/RAG) y **Gemini 3 Flash** (visión) están **completamente integrados** como modelos primarios en la versión actual del sistema. Para garantizar resiliencia, la aplicación cuenta con un `ModelManager` que, al iniciarse, prueba automáticamente la disponibilidad de cada modelo (enviando una llamada de prueba). Si detecta límite de cuota (error 429), promueve de forma autónoma el modelo de fallback: `gpt-4o-mini` para chat y `gpt-4o` para visión, sin intervención del usuario.

---

4. Cálculo Estimado del Costo por Usuario

Quería saber cuánto me costaría mantener esta aplicación en tiempo real una vez terminada. Imaginemos que tengo un usuario frecuente que durante un mes entero (30 días) usa la aplicación todos los días: * Sube **90 fotos** de comidas (3 platos al día en promedio). * Hace **150 preguntas** en el chat (5 consultas al día).

A. Costo de analizar las fotos (Gemini 3 Flash para Entity Recognition): - Calculo que usaré unos 45,000 tokens de entrada (prompts e imágenes) y 10,000 tokens de salida al mes. - A las tarifas oficiales extraídas de Arena.ai ($0.50 in / $3.00 out), el procesamiento de imágenes por mes costará: **$0.052 USD mensuales.**

B. Costo del Chat RAG (Gemini 3.1 Pro Preview): - Calculo unos 300,000 tokens

de entrada al mes por enviarle constantemente los fragmentos del manual GAPA para que los lea ($0.60 USD). - Y 45,000 tokens de salida por las respuestas redactadas al usuario ($0.54 USD). - Total de chat al mes: **$1.14 USD mensuales.**

C. Base de datos Nutricional (USDA FoodData Central): - Como uso un servicio gubernamental público de USA de libre conexión, su costo es exacto de **$0.00 USD.**

Costo Total Mensual Estimado: ~$1.19 USD por Usuario.

Conclusión Financiera: Rediseñar un proyecto "desde cero" con parámetros empíricos reales aterriza las expectativas. Utilizando al campeón comercial de *Entity Recognition* (**Gemini 3 Flash**, 7.4s Latencia) para analizar las fotos, y a un robusto Top #3 global en obediencia clínica hispana (**Gemini 3.1 Pro Preview**) para el texto médico RAG, logro regalar un asistente nutricional inquebrantable por apenas **~$1.19 dólares mensuales** por afiliado constante. Este cálculo es la perla técnica que demuestra la rentabilidad absoluta de escalar la StartUp a niveles masivos sin sacrificar la seguridad médica del usuario.

---

6. Arquitectura Web: Flask con Arquitectura Hexagonal

¿Por qué Flask?

Elegí **Flask** porque es el framework web Python más simple y directo, apropiado para la escala de un proyecto académico como este. No impone convenciones de carpetas ni de base de datos, lo que me permitió aplicar libremente la Arquitectura Hexagonal sin que el framework la contradijera. Además, soporta nativamente respuestas de tipo `text/event-stream` (SSE), que fue clave para mostrar el progreso del agente en tiempo real sin necesidad de WebSockets ni librerías adicionales.

¿Por qué Arquitectura Hexagonal?

La **Arquitectura Hexagonal** organiza la aplicación en tres capas: dominio, aplicación e infraestructura. Su beneficio más concreto fue la **intercambiabilidad de componentes sin tocar la lógica de negocio**: cuando reemplazo OpenAI por Gemini, los casos de uso no cambian porque solo hablan con la interfaz `ILlmAdapter`. Lo mismo aplica a la base de datos: migrar de SQLite a PostgreSQL implicaría modificar un único archivo de repositorio, sin afectar los casos de uso ni el dominio.

---

7. Mejoras Implementadas Desde la Primera Entrega

Desde la primera entrega, el proyecto incorporó mejoras orientadas principalmente a la experiencia del usuario y a la confiabilidad de las respuestas de IA:

- **Lectura de etiquetas nutricionales por OCR**: El sistema sumó un modo de detección automática: cuando el usuario sube una foto de un producto industrial en lugar de un plato, el agente reconoce la etiqueta nutricional y extrae sus valores directamente del texto impreso (incluyendo fibra, sodio, azúcar y tamaño de porción), en lugar de estimarlos visualmente.
- **Respuestas más consistentes**: Al configurar los modelos con temperatura cero y forzar un razonamiento explícito en el prompt de visión, se eliminó la variabilidad estocástica. Analizar la misma foto dos veces ahora entrega el mismo resultado. Además, el sistema selecciona inteligentemente la variante correcta del alimento en USDA según el método de cocción detectado (e.g., "pollo a la plancha" en lugar de "pollo crudo").
- **Panel de razonamiento en tiempo real**: El usuario puede observar en vivo cada paso del agente: qué herramienta está usando, qué está buscando en las guías alimentarias y cuándo comienza a redactar la respuesta. Esto reemplazó un simple spinner estático y hace el comportamiento del agente transparente.
- **Mensajes de error comprensibles**: Cuando un modelo falla (cuota agotada, timeout, autenticación), el usuario ya no ve un error técnico. Un módulo centralizado traduce todas las excepciones a mensajes claros en español.
- **Continuidad del servicio (contexto académico)**: Se implementó un

ModelManager que, cuando el modelo primario (Gemini) agota su cuota, cambia automáticamente al modelo de respaldo (GPT-4o-mini o GPT-4o). Esta funcionalidad surgió de una necesidad práctica del entorno de desarrollo: la cuota gratuita de Gemini se agotaba rápidamente durante las pruebas, lo que hacía inviable continuar ejecutando el proyecto sin un fallback. En un sistema productivo con una suscripción paga, este mecanismo no sería necesario de la misma manera, aunque sí podría adaptarse como estrategia de resiliencia ante fallos de disponibilidad del proveedor.

---

8. Posibles Mejoras Futuras

A futuro, se podrían extender las capacidades de la plataforma con las siguientes funcionalidades:

1. **Reestimación del Costo por Usuario:** El análisis de costo realizado en la Sección 4 fue elaborado de forma teórica, previo a varios cambios significativos en el sistema (OCR de etiquetas, herramientas MCP, entre otros). Antes de escalar el sistema, es necesario reestimar el costo mensual real basándose en el consumo efectivo de tokens.
2. **Evaluación de la Exactitud del Agente:** Antes de una salida a producción formal, se debe medir la exactitud del sistema para verificar que está funcionando correctamente. Para el pipeline de visión, esto implica comparar los macros estimados por el agente contra valores de referencia certificados en USDA. Para el chat RAG, implica evaluar la fidelidad de las respuestas al corpus GAPA mediante técnicas como RAGAS. El objetivo es definir y validar métricas de aceptación claras antes de exponer el sistema a usuarios reales.
3. **Expansión de la Base de Conocimiento (RAG):** Agregar nuevos documentos de salud oficiales, como protocolos de medicina deportiva o normativas pediátricas/geriátricas de la OMS, para ampliar el alcance clínico del asistente más allá de las GAPA actuales.
4. **Integración con Wearables y Ecosistema Fitness:** Conectar la API con *Apple Health* o *Google Fit* para incorporar el gasto calórico por actividad física al cálculo diario de macros, haciendo el seguimiento más preciso para usuarios activos.
5. **Interacción por Voz:** Sumar transcripción de audio con modelos como *Whisper* para que el usuario pueda registrar comidas narrando lo que come, eliminando la necesidad de escribir o sacar fotos en todo momento.
6. **Planificación de Menús Semanales:** Agregar un caso de uso donde el agente genere un plan de comidas personalizado para la semana, respetando los objetivos calóricos del perfil y las preferencias o restricciones declaradas.

9. Ejecución del Proyecto

Para ejecutar este proyecto, por favor sigue las instrucciones detalladas en el archivo README.md.